Tarea 3: Fundamentos de Procesamiento de Imágenes IEE2714

Adrian Godoy

30 de octubre de 2026

Repositorio: `https://github.com/adrianalessandro/fundamentos_img_tarea_3`

---

1. Pregunta 1: eliminación de ruido periódico

1.1. Datos y procedimiento

La imagen `P1.CR2` se convirtió a escala de grises y se normalizó al intervalo $[0, 1]$. Su tamaño es 1504×2256 y su rango es [0,180, 1,000]. El ruido periódico se identificó en el espectro de magnitud logarítmica. La componente principal se seleccionó en $(u, v) = (1058, 0)$ y se trabajó también con $(-1058, 0)$.



Figura 1: Imagen de entrada en escala de grises.

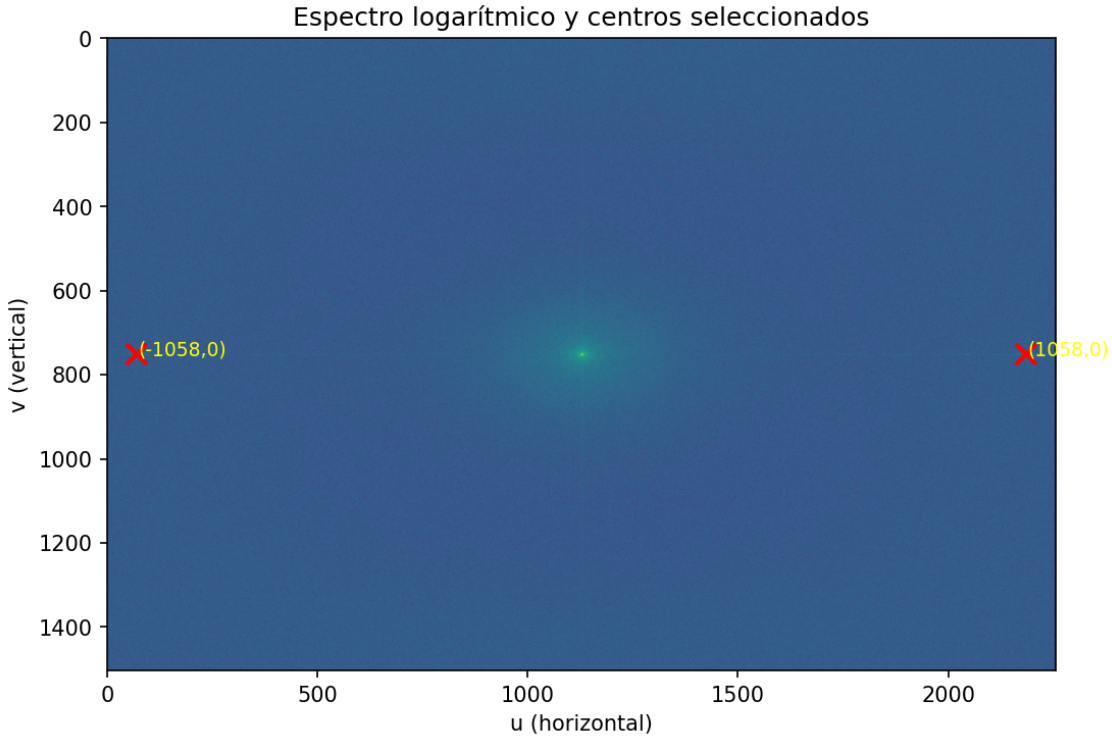


Figura 2: Espectro de magnitud logarítmica y posiciones seleccionadas.

La cadena implementada extiende la imagen mediante reflexión, calcula la FFT 2D centrada, construye una máscara notch, multiplica el espectro complejo por ella, aplica la transformada inversa y elimina los bordes agregados. Se usó un padding configurable de $(32, 32)$ píxeles por borde.

El filtro ideal asigna cero dentro de discos de radio w y uno fuera. El filtro Gaussiano usa

$$H(u, v) = 1 - \exp\left(-\frac{d^2}{2w^2}\right),$$

donde d es la distancia al centro del notch. En ambos casos se pueden entregar varios pares simétricos.

1.2. Anchos de notch

Se probaron $w = 1, 2, 3, 5$. La tabla muestra la desviación estándar y la media absoluta de la diferencia entre la imagen original y la filtrada.

Filtro	$w = 1$	$w = 2$	$w = 3$	$w = 5$
Ideal, desviación estándar	0.01576	0.01702	0.01741	0.01771
Gaussiano, desviación estándar	0.01261	0.01534	0.01636	0.01715
Ideal, media absoluta	0.01370	0.01455	0.01496	0.01532
Gaussiano, media absoluta	0.01112	0.01334	0.01422	0.01492

Tabla 1: Medidas de diferencia para los anchos probados.

Un notch más ancho elimina más frecuencias, pero también puede quitar detalles útiles. El filtro Gaussiano cambia gradualmente. Para el análisis principal se eligió $w = 2$, porque elimina la componente sin hacer demasiado agresiva la atenuación.

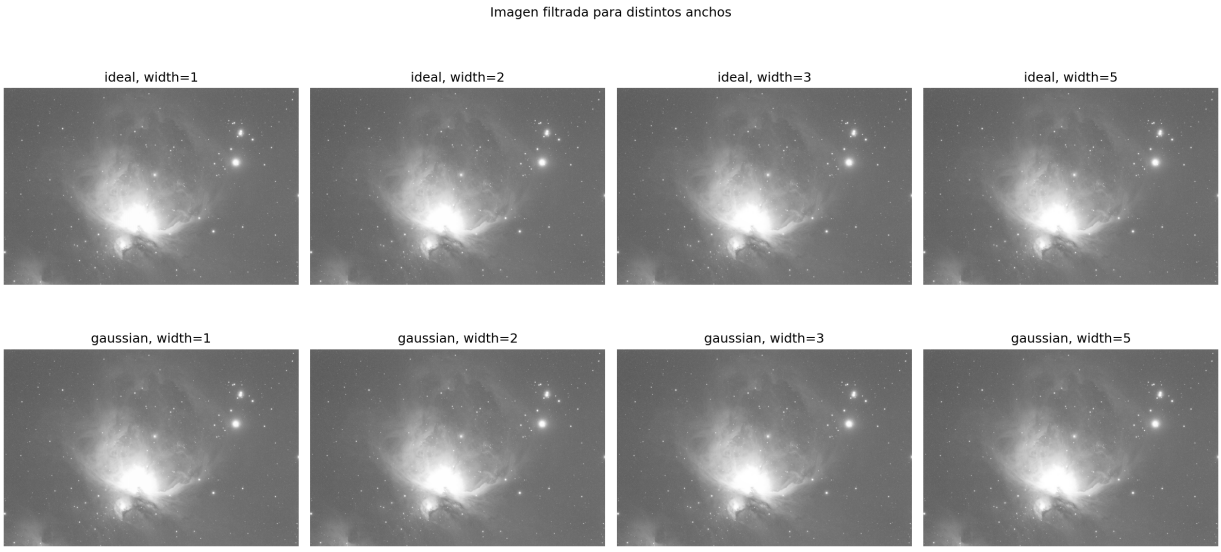


Figura 3: Resultados para filtros ideal y Gaussiano con distintos anchos.

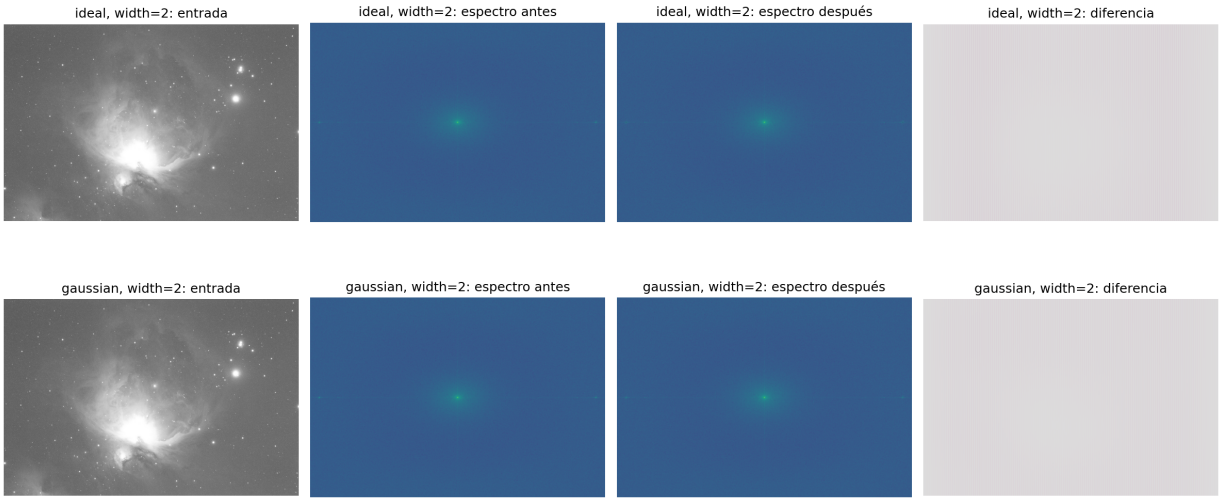


Figura 4: Imagen, espectro antes, espectro después y diferencia para $w = 2$.

1.3. Efecto del padding

Se compararon paddings de $(0, 0)$, $(32, 32)$ y $(64, 64)$ usando el filtro Gaussiano de ancho 2. Las desviaciones estándar de la diferencia fueron 0,01510, 0,01534 y 0,01556, respectivamente. Las medias absolutas fueron 0,01305, 0,01334 y 0,01362.

El padding reflectivo reduce discontinuidades artificiales en los bordes. Las medidas son cercanas, pero el padding de 32 píxeles ofrece una extensión suficiente sin aumentar innecesariamente el costo.

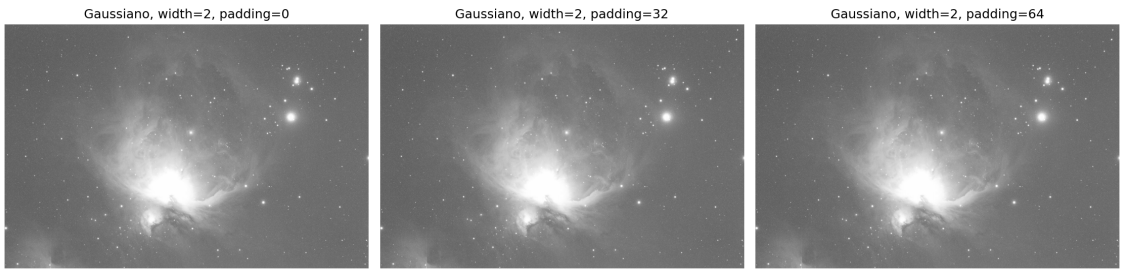


Figura 5: Comparación del filtro Gaussiano para tres tamaños de padding.

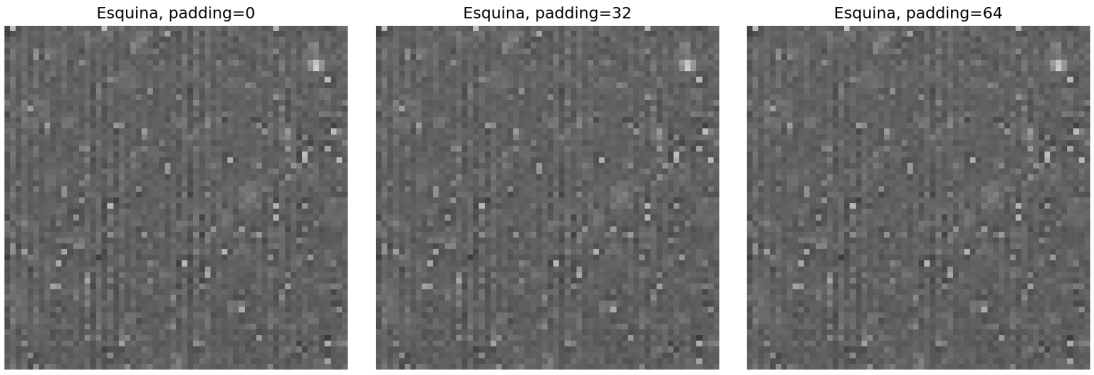


Figura 6: Recorte ampliado de la esquina superior izquierda.

1.4. Configuración final

La configuración seleccionada fue el filtro notch Gaussiano, ancho $w = 2$ y padding reflectivo $(32, 32)$. En el espectro con padding, el centro se escala a $(1088, 0)$. Para esa frecuencia se obtuvo

$$\begin{aligned} F_{\text{antes}} &= -3{,}330183 \times 10^{2} + 2{,}630324 \times 10^{4}\, j, \\ H &= 0, \\ F_{\text{después}} &= 0 + 0\, j. \end{aligned}$$

La comprobación de $F_{\text{después}} - H F_{\text{antes}}$ fue $0{,}000 \times 10^{0}$.



Figura 7: Entrada, resultado final y diferencia.

1.5. Preguntas guiadas

¿Por qué aparecen componentes simétricas? Una sinusoidal real puede escribirse como la suma de dos exponenciales complejas de frecuencias opuestas. Por eso su transformada tiene componentes en $+f$ y $-f$. Además, la FFT de una imagen real tiene simetría conjugada: $F(-u,-v) = \text{conj}(F(u,v))$. El código recorre cada centro (u,v) junto con $(-u,-v)$.

Coordenadas y distancia. `frequency_coordinates` construye matrices U, V enteras con origen en el centro. Para (u_c, v_c) usa $d^2 = (U-u_c)^2 + (V-v_c)^2$. El filtro ideal compara $d^2 \leq w^2$, mientras el Gaussiano usa $1 - \exp(-d^2/(2w^2))$.

Padding y recorte. `np.pad(..., mode=reflect)` refleja 32 filas y 32 columnas en cada borde. Después de la IFFT, `crop_padding` elimina esos bordes y recupera 1504×2256. El caso de padding cero también se maneja.

¿Por qué filtrar el espectro complejo? La magnitud indica cuánto hay de cada frecuencia, pero la fase contiene su ubicación y estructura espacial. Multiplicar el complejo conserva ambas informaciones y aplica la transferencia completa.

Valor complejo solicitado. Para $(u,v) = (1088, 0)$ se obtuvo el valor complejo mostrado arriba. Como $H = 0$, el valor posterior es cero y la comprobación coincide hasta el redondeo numérico.

¿Qué pasa con un solo notch? Se elimina solo una de las componentes conjugadas. El espectro deja de corresponder a una imagen real y la IFFT puede contener una parte imaginaria, artefactos o una cancelación incompleta. Por eso se usa siempre el par.

2. Pregunta 2: restauración de imágenes

2.1. Datos y construcción de la degradación

Se usó `cameraman.jpg` en escala de grises, normalizada en $[0, 1]$, con tamaño 256×256. La PSF `psf.png` tiene tamaño 15×15 y se normalizó para que su suma fuera uno. Para obtener H, la PSF se insertó en una matriz del tamaño de la imagen, se desplazó su centro al origen de convolución y se aplicó la FFT.

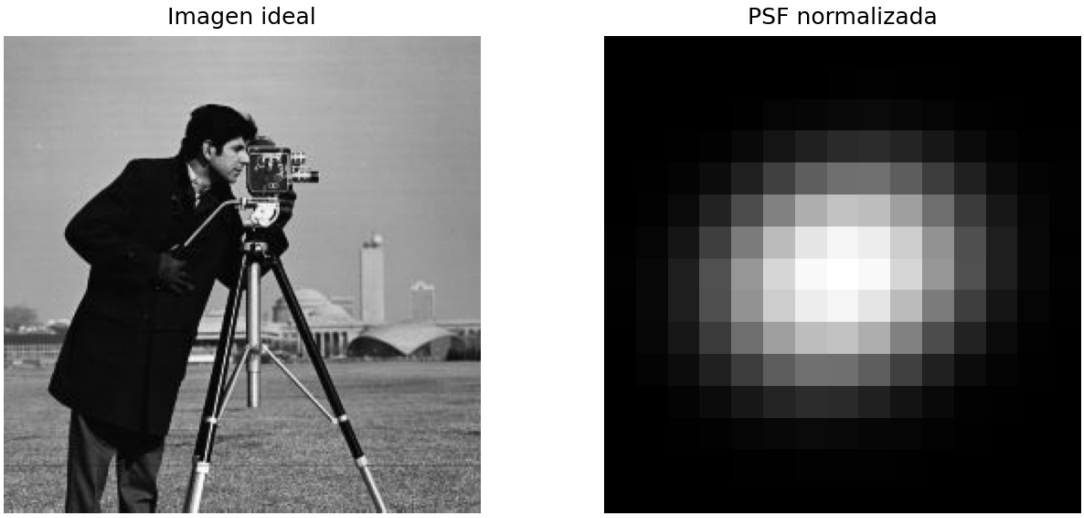


Figura 8: Imagen ideal y PSF normalizada.

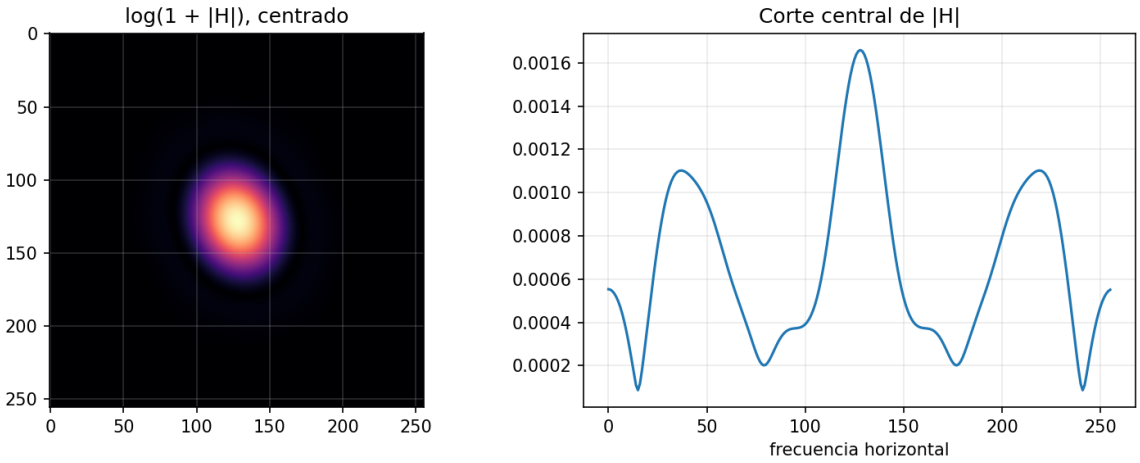


Figura 9: Respuesta en frecuencia de la PSF.

La observación se generó como $y = h * x + n$, usando ruido Gaussiano con $\sigma = 0{,}01$ y $\sigma = 0{,}03$. Los rangos observados fueron $[0{,}003, 0{,}901]$ y $[-0{,}077, 0{,}936]$.

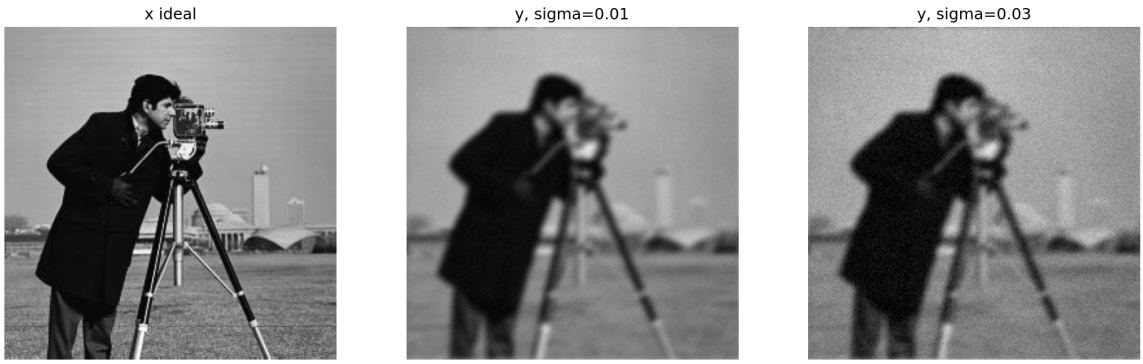


Figura 10: Imagen ideal y observaciones con dos niveles de ruido.

2.2. Filtro de Wiener

Se implementó directamente

$$\widehat{X}(u,v) = \frac{H^*(u,v)Y(u,v)}{|H(u,v)|^2 + K}.$$

Se probaron 31 valores de K entre 10^{-6} y 10^{-1} en escala logarítmica.

σ	K óptimo	RMSE mínimo
0.01	$4{,}642 \times 10^{-3}$	0.065744
0.03	$2{,}154 \times 10^{-2}$	0.072766

Tabla 2: Selección de K mediante RMSE.

Cuando el ruido aumenta, el mejor K también aumenta: se necesita una regularización mayor para evitar amplificar frecuencias poco confiables.

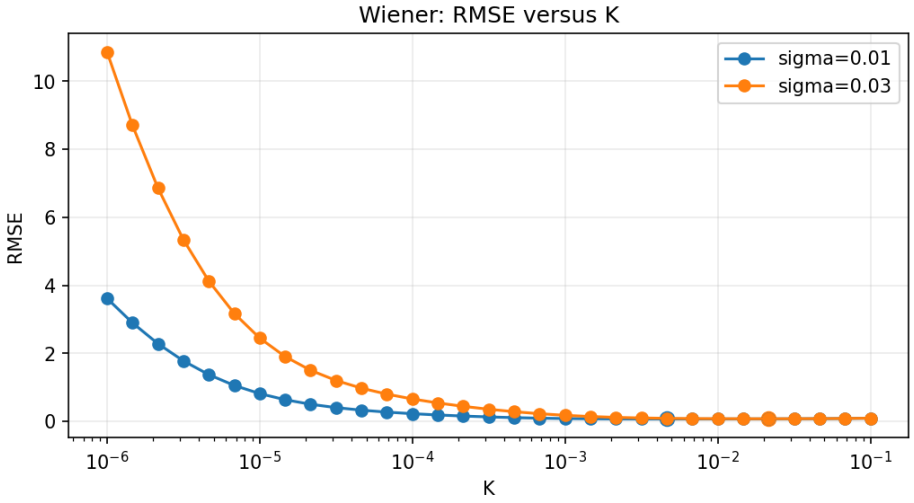


Figura 11: RMSE en función de K.

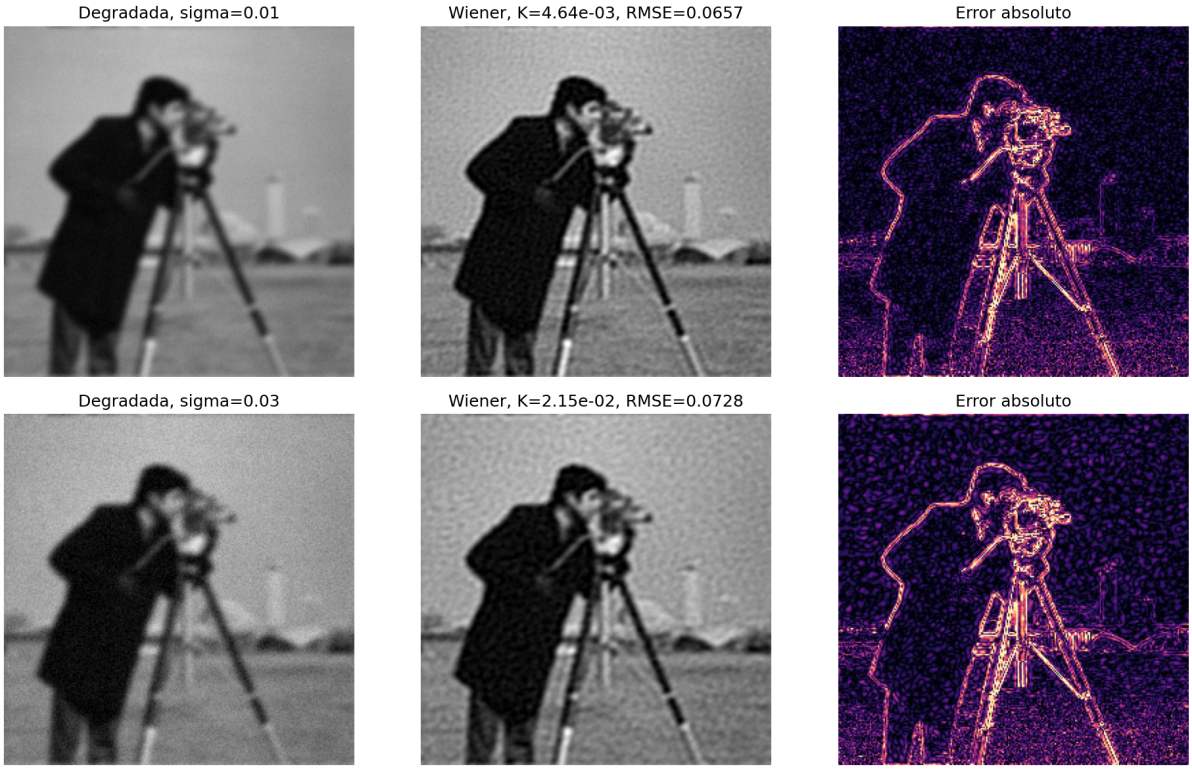


Figura 12: Reconstrucciones de Wiener para ambos niveles de ruido.

2.3. Sensibilidad a la PSF

Para medir la sensibilidad del modelo, la PSF se desplazó un píxel horizontalmente antes de construir la respuesta en frecuencia. Con $\sigma = 0{,}03$ y el K óptimo, la PSF correcta obtuvo RMSE 0,072766, mientras que la PSF desplazada obtuvo RMSE 0,080423.



Figura 13: Efecto de usar una PSF desplazada un píxel.

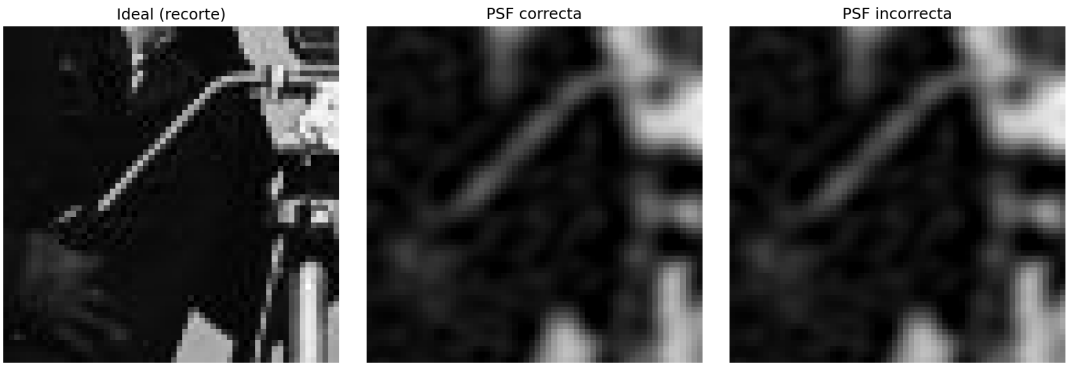


Figura 14: Recorte ampliado de la sensibilidad a la PSF.

2.4. Tikhonov por descenso de gradiente

Se minimizó

$$J(x) = \frac{1}{2}\|h * x - y\|_2^2 + \frac{\lambda}{2}\|x\|_2^2$$

con

$$x^{k+1} = x^k - \tau\left(H^T(Hx^k - y) + \lambda x^k\right).$$

El operador directo y su adjunto se implementaron mediante FFT, usando H y H^*, respectivamente. Se guardó el costo y el RMSE en cada iteración.

Se probaron $\lambda = 10^{-5}, 10^{-3}, 10^{-2}$ y además $\lambda = K = 2{,}154 \times 10^{-2}$, junto con $\tau = 1{,}0, 2{,}2$. Con $\tau = 1{,}0$ el descenso fue estable. Con $\tau = 2{,}2$ el costo creció mucho; para $\lambda = 10^{-2}$ el RMSE final alcanzó aproximadamente $1{,}32 \times 10^{10}$. Un paso demasiado grande vuelve inútil la iteración. Los valores pequeños de λ conservan más información pero convergen hacia soluciones más sensibles al ruido; el valor mayor regulariza más y produce un costo final mayor. Ninguna corrida terminó antes del máximo de 120 iteraciones, por lo que en esta configuración el criterio de detención no se activó y el límite fue el que controló la duración.

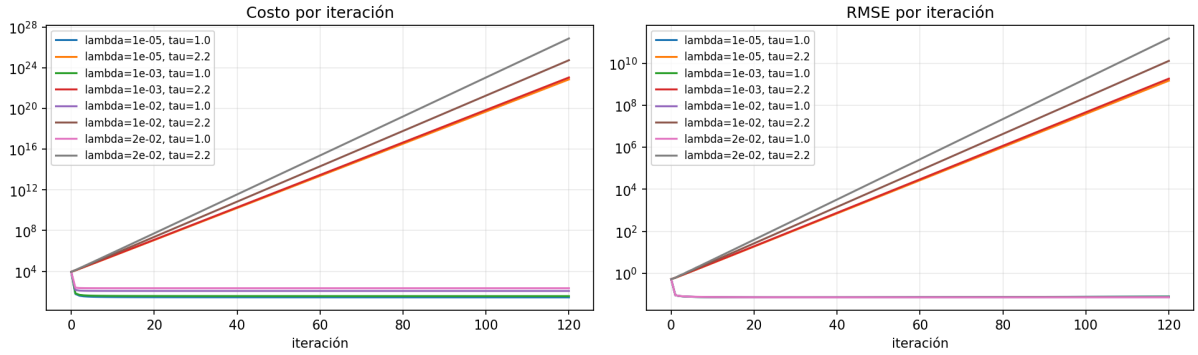


Figura 15: Costo y RMSE durante el descenso de gradiente.

2.5. Comparación con la solución cerrada

La solución cerrada usada fue

$$\widehat{X}_\lambda = \frac{H^* Y}{|H|^2 + \lambda}.$$

Para $\lambda = K = 2{,}154 \times 10^{-2}$, la solución cerrada obtuvo RMSE 0,072766 y la iterativa 0,072759; la diferencia entre ambas fue $7{,}835 \times 10^{-5}$. Por lo tanto, con un paso estable y suficientes iteraciones, ambas soluciones coinciden prácticamente.

Para $\lambda = 0$, la solución cerrada tuvo RMSE 155,536560, porque intenta invertir frecuencias donde $|H|$ es muy pequeño. La solución iterativa obtuvo 0,126537 dentro del número limitado de iteraciones, pero tampoco representa una restauración regularizada completa.



Figura 16: Comparación entre soluciones cerrada e iterativa y recortes.

2.6. Preguntas guiadas

¿Por qué la inversión directa Y/H es inestable? En frecuencias donde $|H|$ es pequeño, dividir por H amplifica el ruido y cualquier error numérico. El término K agrega un denominador positivo $|H|^2 + K$, limitando esa amplificación.

¿Cómo se transforma la PSF en $H(u, v)$? `psf_to_frequency` normaliza la PSF, la inserta en una matriz del tamaño de la imagen, desplaza su centro $(h//2, w//2)$ al índice $(0, 0)$ mediante `roll` y aplica `fft2`. Omitir el desplazamiento produce una fase lineal y desalineación.

¿Cuál es el gradiente de Tikhonov? El código calcula el residuo $Hx-y$ y luego $H^T(Hx-y)+\lambda x$. El primer término mide fidelidad a los datos y el segundo es regularización L2. H^T se obtiene

multiplicando por H^* en frecuencia.

¿Qué criterio de detención se usa? Después de cada actualización se calcula

$$\frac{|J_k - J_{k+1}|}{\text{máx}(|J_k|, 10^{-12})}.$$

Si es menor que la tolerancia se detiene el ciclo; también existe el límite `max_iter`.

¿Por qué para $\lambda = K$ coinciden las soluciones cerradas? La ecuación normal de Tikhonov de orden cero es

$$(H^*H + \lambda I)X = H^*Y.$$

Al trabajar en frecuencia, se despeja $X = H^*Y/(|H|^2 + \lambda)$. Esta es la misma expresión del filtro de Wiener cuando $K = \lambda$. Una coincidencia exacta puede verse afectada por el redondeo, las convenciones de centrado o porque la solución iterativa todavía no haya convergido.